

### Misc

- n* ∈ ℕ<sup>\*</sup>, ∀*k* ∈ ℤ, *k* ≥ 4log<sub>2</sub> *n*, 有 *k*! ≥ *n*<sup>3</sup>
- ∀*x* ≥ −1, ln(1+*x*) ≤ *x*; ∀*x* ≤ 1/2, ln(1−*x*) ≥ −*x* − *x*<sup>2</sup>
- exp(*x*) ≥ *x* + 1
- d
d
t





∫

a
(
t
)


b
(
t
)



f
(
x
)
d
x
=
f
(
b
(
t
)
)

b
′
(
t
)


−
f
(
a
(
t
)
)

a
′
(
t
)
- Gram-Schmidt 正交化！
- 期望！**非负离散：



E
(
X
)
=

∑

x
=
0


+
∞



P
(
X
>
x
)
,


连续



E
(
X
)
=

∫

0


+
∞



P
(
X
>
x
)
d
x
,


有分布函数




F

X


(
x
)


的话



E
(
X
)
=

∫

0


+
∞



(
1
−

F

X


(
x
)
)
d
x
.


如果分段函数要注意分段之前的部分 1 也有积分贡献。
- 高斯积分：




∫

−
∞


+
∞



e

−
t

x

2




d
x
=


√
π

t
- 分部积分：



∫
u
d
v
=
u
v
−
∫
v
d
u
- 凑微分：



∫
d
f
(
u
)
=
∫

f
′
(
u
)
d
u
- ln(1−*x*) = −




∑

k
≥
1





x

k


k


, (1+*x*)<sup>α</sup> = 




∑

k
≥
0





(


α


k



)

x

k
- ∫
(
a
x
+
b
)

n


d
x
=


(
a
x
+
b
)

n
+
1




a
(
n
+
1
)



+
C
,


也即



∫

x

n


d
x
=


x

n
+
1




n
+
1



+
C
- 伽马函数相关性质

$$\Gamma(\alpha)=\int_0^{\infty}x^{\alpha-1}e^{-x}\mathrm{d}x$$

$$\Gamma(\alpha+1)=\alpha\cdot\Gamma(\alpha),\Gamma(n+1)=n!,\Gamma(n+\tfrac{1}{2})=\tfrac{(2n)!}{4^n n!}\sqrt{\pi}$$

### 1 概率论基本概念

**概率公理化**：*S* 为样本空间，*F* 为 *S* 的某些子集组成的事件域。如果定义在 *F* 上的实值函数 *P* 满足。1. ∀*A* ∈ *F*, *P*(*A*) ≥ 0；2. *P*(*S*) = 1；3. ∀*A*<sub>1</sub>, *A*<sub>2</sub>, ... ∈ *F* 且两两互斥，有 



P
(

⋃

i
=
1


∞



A

i


)
=

∑

i
=
1


∞



P
(

A

i


)
,


则称 *P* 为概率测度，(*S*,*F*,*P*) 为概率空间。

**一般加法公式** 



P
(

⋃

i
=
1


n



A

i


)
=

∑

i
=
1


n



P
(

A

i


)
−

∑

1
≤
i
<
j
≤
n



P
(

A

i


A

j


)
+
⋯
+
(
−
)

n
−
1



P
(

A

1


⋯

A

n


)

**贝叶斯公式** 



P
(
A
|
B
)
=
P
(
B
|
A
)
⋅


P
(
A
)
P
(
B
)

相互独立比两两独立**更强**。

**Union Bound** 



P
(

⋃

A

i


)
≤

∑
P
(

A

i


)
,


对 *A*<sub>*i*</sub> 无要求。

**证明存在可以通过证明其概率大于 0**

### 2 离散随机变量

P
(
X
≥
E
(
X
)
)
>
0
,
P
(
X
≤
E
(
X
)
)
>
0
,
V
a
r
(
a
X
+
b
)
=

a

2



V
a
r
(
X
)

尾不等式/集中不等式：随机变量与期望的偏离。

**Markov**：对**非负** *X*，*E*(*X*)>0,*a*>0，有

$$P(X\geq a)\leq \frac{E(X)}{a}\quad P(X\geq aE(X))\leq \frac{1}{a}$$

**Chebyshev**: 对 σ(*X*)>0,*c*>0，

$$P(|X-E(X)|\geq c\cdot\sigma(X))\leq 1/c^2$$

$$P(|X-E(X)|\geq a)\leq \mathrm{Var}(X)/a^2$$

分布	分布列 <span><span>    P ( X = k ) =   </span></span>	期望	方差
<i>B</i> ( <i>n</i> , <i>p</i> )	<span><span>        (   n   k    )    p  k    ( 1 −<!-- − --> p  )  n −<!-- − --> k     </span></span>	<i>np</i>	<i>np</i> (1− <i>p</i> )
<i>G</i> ( <i>p</i> )	<span><span>    p  ( 1 −<!-- − --> p  )  k −<!-- − --> 1     </span></span>	<span><span>    1 p   </span></span>	<span><span>    1 −<!-- − --> p  p  2     </span></span>
π( <i>λ</i> )	<span><span>     λ<!-- λ -->  k    e  −<!-- − --> λ<!-- λ -->    /  k !   </span></span>	<i>λ</i>	<i>λ</i>
<i>NB</i> ( <i>r</i> , <i>p</i> )	<span><span>        (   k −<!-- − --> 1   r −<!-- − --> 1    )    p  r    ( 1 −<!-- − --> p  )  k −<!-- − --> r     </span></span>	<span><span>    r p   </span></span>	<span><span>       r ( 1 −<!-- − --> p )    p  2     </span></span>

**二项分布**：*n* 次独立重复伯努利实验成功次数。**几何分布**：第一次成功的试验次数。**负二项分布**：第 *r* 次成功的次数。有 *G*(*p*)=*NB*(1,*p*)。**泊松分布**：单位时间内事件发生次数。几何分布具有**无记忆性**：



P
(
X
>
m
+
n
|
X
>
m
)
=
P
(
X
>
n
)
.


*NB*(*r*,*p*) 可以拆成 *r* 个独立的 *G*(*p*) 之和。

### 3 连续随机变量

**正态分布**：



X
∼
N
(
μ
,

σ

2


)
,
f
(
x
)
=



1


√

2
π

σ



exp
⁡
(
−


(
x
−
μ
)

2




2

σ

2




)
,

E
(
X
)
=
μ
,
V
a
r
(
X
)
=

σ

2


.


标准正态分布 



Z
∼
N
(
0
,
1
)
.

**指数分布**：



X
∼
Exp
(
λ
)
,
f
(
x
)
=
λ

e

−
λ
x


,
F
(
x
)
=
1
−

e

−
λ
x


,

E
(
X
)
=
1
/
λ
,
V
a
r
(
X
)
=
1

/

λ

2


.


具有无记忆性 



P
(
X
>
s
+
t
|
X
>
s
)
=
P
(
X
>
t
)
.


理解为泊松分布假设下，第一次事件发生的时刻。

**伽马分布**：



X
∼
Γ
(
α
,
λ
)
,


理解为泊松假设下第 *α* 次的时刻。

$$f(x)=\frac{\lambda^{\alpha}}{\Gamma(\alpha)}x^{\alpha-1}e^{-\lambda x},x\geq 0$$

E
(
X
)
=
α
/
λ
,
V
a
r
(
X
)
=
α
/

λ

2


.


具有可加性：



Γ
(

α

1


+

α

2


,
λ
)
=
Γ
(

α

1


,
λ
)
+
Γ
(

α

2


,
λ
)
.


α=1 时即指数分布。α=*n*/2,λ=1/2 时即 




χ

2


(
n
)


分布。

**概率密度变换**：



Y
=
g
(
X
)
,
g


单调且反函数 *h*(*y*) 有连续导数，则 




f

Y


(
y
)
=

f

X


(
h
(
y
)
)
⋅
|

h
′
(
y
)

|
.


如果没法直接套这个公式的话可以从**分布函数**的定义出发进行变换。即先算 



P
(
Y
≤
y
)


再求导。

### 4 多维离散随机变量

对于**独立**的 *X*,*Y*，有 Var(*X*±*Y*)=Var(*X*)+Var(*Y*)

**协方差**：Cov(*X*,*Y*)=*E*((*X*−*E*(*X*))(*Y*−*E*(*Y*)))=*E*(*XY*)−*E*(*X*)*E*(*Y*)。

Var(*X*<sub>1</sub>+⋯+*X*<sub>*n*</sub>)=




∑

i


∑

j


C
o
v
(

X

i


,

X

j


)
,

Var(*X*+*Y*)=Var(*X*)+Var(*Y*)+2Cov(*X*,*Y*),

Cov(*aX*,*bY*)=*ab*·Cov(*X*,*Y*), Cov(*X*<sub>1</sub>+*X*<sub>2</sub>,*Y*)=Cov(*X*<sub>1</sub>,*Y*)+Cov(*X*<sub>2</sub>,*Y*),

Cov(*X*,*Y*) ≤ 





√


V
a
r
(
X
)
V
a
r
(
Y
)

**条件期望**：



E
(
X
|
Y
=
y
)
=

∑

i



x

i



P
(
X
=

x

i


|
Y
=
y
)
,


是关于 *y* 的函数。

*E*(*X*|*Y*) 是随机变量。

**重期望公式**：



E
(
E
(
X
|
Y
)
)
=
E
(
X
)

### 5 多维连续随机变量

**条件分布函数**：



F
(
x
|
y
)
=
P
(
X
≤
x
|
Y
=
y
)
=

∫

x


−
∞



f


f

Y


(
y
)



d
u

**条件密度函数**：



f
(
x
|
y
)
=



∂


∂
x





F
(
x
|
y
)
=


f
(
x
,
y
)


f

Y


(
y
)


.

**二维高斯**：



X
,
Y
∼
N
(

μ

1


,

μ

2


,

σ

1

2


,

σ

2

2


,
ρ
)
,


要求 |ρ|<1。

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left[-\frac{1}{2(1-\rho^2)}\left(\frac{(x-\mu_1)^2}{\sigma_1^2}+\frac{(y-\mu_2)^2}{\sigma_2^2}-\frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2}\right)\right]$$

边际密度函数与 ρ 无关，即 



X
∼
N
(

μ

1


,

σ

1

2


)
,
Y
∼
N
(

μ

2


,

σ

2

2


)
.


ρ=0 时独立。协方差 Cov(*X*,*Y*)=ρσ<sub>1</sub>σ<sub>2</sub>。给定条件 *Y*=*y*，*X* 的条件分布服从 



N
(

μ

1


+
ρ


σ

1


σ

2



(
y
−

μ

2


)
,

σ

1

2


(
1
−

ρ

2


)
)

**相关系数** Corr(*X*,*Y*)=Cov(*X*,*Y*)/σ(*X*)σ(*Y*)。相关系数/协方差大于 0 则正相关，小于 0 则负相关，等于 0 则不相关（但不一定独立）。相关系数等于 ±1 代表 *X*,*Y* 呈严格线性关系。证明考虑标准化 





X
˜


,


Y
˜
, 然后通过 Var(





X
˜


−


Y
˜
)=0 推导出 



P
(


X
˜


−


Y
˜



=
c
)
=
1
.

#### 5.1 概率密度变换

**卷积公式**：若 *X*,*Y* 独立，*Z*=*X*+*Y*，则

$$f_Z(z)=\int_{-\infty}^{\infty}f_X(x)f_Y(z-x)\mathrm{d}x=\int_{-\infty}^{\infty}f_X(z-y)f_Y(y)\mathrm{d}y$$

**min/max**：若 *X*<sub>1</sub>,⋯,*X*<sub>*n*</sub> 独立，则 



Y
=
max
{

X

i


}


 的分布函数为 




F

Y


(
y
)
=

∏

i
=
1


n



F

X

i


(
y
)
,

Y
=
min
{

X

i


}


 的分布函数为 




F

Y


(
y
)
=
1
−

∏

i
=
1


n



(
1
−

F

X

i


(
y
)
)
.

**换元**：*X*,*Y* 的概率密度为 *f*(*x*,*y*)，函数 *u*=*u*(*x*,*y*) 和 *v*=*v*(*x*,*y*) 偏导连续且 



x
=
x
(
u
,
v
)
,
y
=
y
(
u
,
v
)


为唯一反函数，则 



U
=
u
(
X
,
Y
)
,
V
=
v
(
X
,
Y
)


的联合概率密度为

$$g(u,v)=f(x(u,v),y(u,v))\cdot|J|,J=\left|\frac{\partial(x,y)}{\partial(u,v)}\right|=\left|\frac{\partial x}{\partial u}\frac{\partial y}{\partial v}-\frac{\partial x}{\partial v}\frac{\partial y}{\partial u}\right|$$

### 5.2 线性代数

**对角化**：***A*=*PAP*<sup>−1</sup>**。保行列式，平方的行列式和 trace 不变。实对称矩阵可对角化，不同特征值的特征向量正交。

**正定**：半正定矩阵 ***A*** 存在 ***B*=*A*<sup>1/2</sup>**，***B*<sup>⊤</sup>*B*=*B*<sup>2</sup>=*A***，且 *B* 不唯一。对于正定矩阵，这样的 ***B*** 可逆，(***B*<sup>−1</sup>**)<sup>2</sup>=***A*<sup>−1</sup>**。

**协方差矩阵**：对于随机变量 ***X*=(*X*<sub>1</sub>,⋯,*X*<sub>*n*</sub>)**，Cov(***X***)=*E*((***X*−*E*(***X*)**)(***X*−*E*(***X*)**)<sup>⊤</sup>) 为协方差矩阵，有****

$$\mathrm{Cov}(\boldsymbol{X})=\begin{pmatrix}\mathrm{Var}(X_1)&\mathrm{Cov}(X_1,X_2)&\cdots&\mathrm{Cov}(X_1,X_n)\\ \mathrm{Cov}(X_2,X_1)&\mathrm{Var}(X_2)&\cdots&\mathrm{Cov}(X_2,X_n)\\ \vdots&\vdots&\ddots&\vdots\\ \mathrm{Cov}(X_n,X_1)&\mathrm{Cov}(X_n,X_2)&\cdots&\mathrm{Var}(X_n)\end{pmatrix}$$

其对称且半正定。

**高斯**：*n* 维高斯的联合密度函数，***B*** 为协方差矩阵：

$$f(\boldsymbol{x})=\frac{1}{(2\pi)^{\frac{n}{2}}(\det\boldsymbol{B})^{\frac{1}{2}}}\exp\left(-\frac{1}{2}\cdot(\boldsymbol{x}-\boldsymbol{\mu})^{\top}\boldsymbol{B}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right)$$

若 



X
∼
N
(
μ
,
B
)
,


令 ***Y*=*A**X*+*b***，且 ***A*** 行满秩，则 



Y
∼
N
(
A
μ
+
b
,
A
B
A

⊤


)

### 5.3 结论

- 对于独立的 




X

i


∼
N
(

μ

i


,

σ

i


2


)
,


有

$$\sum a_iX_i\sim N(\sum a_i\mu_i,\sum a_i^2\sigma_i^2)$$

- 对于单个 




X

i


∼
N
(
0
,
1
)
,


有 




X

i


2


∼

χ

2


(
1
)
=
Γ
(
1
/
2
,
1
/
2
)
,


且 




∑

i
=
1


n



X

i


2


∼

χ

2


(
n
)
=
Γ
(


n
2


,


1
2


)

### 6 尾不等式、大数定律与中心极限定理

#### 6.1 尾不等式

尾不等式：



P
(
X
≥
k
)


的上界。集中不等式：



P
(
|
X
−
E
(
X
)
|
≥
k
)


的上界。

**矩**：




E

(

X

n


)


称为 *X* 的 *n* 阶矩，



E
(
(
X
−
E
(
X
)

)

n


)


称为 *X* 的 *n* 阶中心矩。切比雪夫不等式的本质是对二阶中心矩使用 Markov。

**矩生成函数**：




M

X


(
t
)
=
E
(

e

t
X


)
=

∑

i
≥
0





t

i




i
!



E

(

X

i


)
.


所以求 *k* 阶矩可以求其封闭形式的 *k* 阶导数后令 *t*=0。

**Chernoff Bound**：求 *k* 阶中心矩然后用 Markov 得到的尾不等式通常较弱（没有真正用到 *n* 重伯努利实验的独立性）。对于任意 *t*>0，有

$$P(X\geq a)=P(e^{tX}\geq e^{ta})\leq \frac{E(e^{tX})}{e^{ta}}=e^{-ta}M_X(t)$$

对于任意 *t*<0 有 



P
(
X
≤
a
)
≤

M

X


(
t
)
⋅

e

−
t
a




通过调节 *t* 可得到更紧的上界。一般而言是**求**寻找最小值。但是 Chernoff Bound 不一定是最紧的。

**Hoeffding 引理**：若实数随机变量 *a* ≤ *X* ≤ *b*，则对任意实数 *t* 有

$$E(e^{t(X-E(X))})\leq \exp\left(\frac{t^2(b-a)^2}{8}\right)$$

**Chernoff-Hoeffding 不等式**：*X*<sub>1</sub>,⋯,*X*<sub>*n*</sub> 独立，且 *a*<sub>*i*</sub> ≤ *X*<sub>*i*</sub> ≤ *b*<sub>*i*</sub>，令 



X
=

∑

i
=
1


n



X

i


,


则对任意 *t*>0 有

$$P(X\geq E(X)+t)\leq \exp\left(\frac{-2t^2}{\sum_{i=1}^n(b_i-a_i)^2}\right)$$

$$P(X\leq E(X)-t)\leq \exp\left(\frac{-2t^2}{\sum_{i=1}^n(b_i-a_i)^2}\right)$$

对于 *a* ≤ *X*<sub>*i*</sub> ≤ *b* 的情况，分母就是 *n*(*b*−*a*)<sup>2</sup>。

## 6.2 尾不等式结论

**矩生成函数的应用**：对于要算  $e^X$  的期望，可以先算矩生成函数然后令  $t=1$ 。

**矩生成函数**：

- $X\sim B(n,p)$ ,  $M_X(t)=(1-p+e^tp)^n$
- $X\sim \pi(\lambda)$ ,  $M_X(t)=\exp(\lambda(e^t-1))$
- $X\sim N(\mu,\sigma^2)$ ,  $M_X(t)=\exp(\mu t+\frac{\sigma^2t^2}{2})$
- $X\sim \text{Exp}(\lambda)$ ,  $M_X(t)=\frac{\lambda}{\lambda-t},t<\lambda$ , 于是  $\Gamma(n,\lambda)$  的矩生成函数为

$$M_X(t)=\left(\frac{\lambda}{\lambda-t}\right)^n,t<\lambda,\chi^2(n)\text{ 的 为 }M_X(t)=(1-2t)^{-\frac{n}{2}},t<1/2$$

**常见 Chernoff-Hoeffding 界**：

- $X\sim \pi(\lambda)$ ,  $P(X\geq x)\leq \frac{e^{-\lambda}(\epsilon\lambda)^x}{x^x}$
- $X\sim N(\mu,\sigma^2)$ ,  $P(X\geq E(X)+k\sigma)\leq \exp(-k^2/2)$
- $X\sim B(n,p)$ ,  $P(|X-E(X)|\geq n\epsilon)\leq 2\cdot \exp(-2n\epsilon^2)$

**对期望分段放缩**：对于  $E(Y)=\sum_{k=1}^n P(Y=k)\cdot k$ ，若我们知道对于  $k>k'$  有  $P(Y=k)\leq c$ ，那么就可以分段放缩：

$$E(Y)=\sum_{k=1}^{k'}P(Y=k)\cdot k+\sum_{k=k'+1}^nP(Y=k)\cdot k$$

左边的  $k$  放成  $k'$ ，右边的放成  $n$ ，然后和  $c$  消掉。

## 6.3 大数定律

**大数定律的一般形式**：对于随机变量  $\{X_n\}$ ，对于任意  $\epsilon>0$ ，若

$$\lim_{n\rightarrow\infty}P\left(\left|\frac{1}{n}\sum_{i=1}^nX_i-\frac{1}{n}\sum_{i=1}^nE(X_i)\right|<\epsilon\right)=1$$

**Markov 大数定律**： $\frac{1}{n^2}\text{Var}(\sum_{i=1}^nX_i)\rightarrow 0$ ，则  $\{X_n\}$  满足大数定律的一般形式。

**辛钦大数定律**： $\{X_n\}$  独立同分布，且  $E(X_i)=\mu$ ，则  $\{X_n\}$  满足大数定律的一般形式。对比 Markov，需要 iid，但不需要方差。

**依概率收敛**：随机变量序列  $\{X_n\}$  依概率收敛于  $X$ ，记作  $X_n\overset{P}{\rightarrow}X$ ，如果对任意  $\epsilon>0$ ，有

$$\lim_{n\rightarrow\infty}P(|X_n-X|\geq\epsilon)=0$$

**依分布收敛**：随机变量序列  $\{X_n\}$  依分布收敛于  $X$ ，记作  $X_n\overset{d}{\rightarrow}X$ ，如果对任意  $x$ ,  $F_{X_n}(x)\rightarrow F_X(x)$ 。**依概率收敛可以推出依分布收敛，反之不亦然**

**几乎必然收敛**：随机变量序列  $\{X_n\}$  几乎必然收敛于  $X$ ，记作  $X_n\overset{a.s.}{\rightarrow}X$ ，如果  $\forall\epsilon>0$

$$\lim_{n\rightarrow\infty}P\left(\bigcup_{m=n}^{\infty}|X_m-X|\geq\epsilon\right)=1$$

## 6.4 应用

### 6.4.1 随机快排

算法：随机一个 pivot  $x$ ，将其余元素排在两侧  $L,R$ ，然后递归  $L,R$ 。如何计算  $E(T)$ ?  $T=O(\sum_{i<j}1C_{i,j})$ ,  $C_{i,j}$  表示  $i,j$  是否比较过。

发现算法比较过  $i,j$  iff  $i$  或  $j$  是  $[i,j]$  中第一个被选为 pivot 的元素。因为每个元素被选为 pivot 的概率相等,  $P(C_{i,j})=\frac{2}{j-i+1}$ 。所以

$$E(T)=\sum_{i<j}\frac{2}{j-i+1}=O(n\log n)。$$

令  $D_i$  表示  $i$  被比较的次数，给出尾不等式。发现若 pivot 落在  $[n/4,3n/4]$  则  $i$  所在数组大小至少减小 1/4，前者概率为 1/2。若至少有  $3\log n$  次，则完成排序。即  $-(3/4)^{3\log n}\leq 1/n$ 。所以  $P(D_i>20\log n)\leq P(X_i<3\log n)$ ,  $X_i\sim B(20\log n,1/2)$ 。  $P(X_i<3\log n)\leq \exp(-4\log n)\leq 1/n^4$ 。Union Bound 一下  $P(T>20n\log n)\leq 1/n^3$ 。

### 6.4.2 JL 降维

结论：给定  $x_i\in\mathbb{R}^n$ ，存在线性映射  $F:\mathbb{R}^n\rightarrow\mathbb{R}^k$ ，其中  $m=O(\epsilon^{-2}\log N)$ ， $\geq 1/2$  概率  $\forall i,j,(1-\epsilon)\|x_i-x_j\|_2^2\leq\|F(x_i)-F(x_j)\|_2^2\leq(1+\epsilon)\|x_i-x_j\|_2^2$ 。  $F=\frac{1}{\sqrt{k}}\cdot Ax$ ，其中  $A$  的每个元素独立服从  $N(0,1)$ 。

思路：对所有可能的  $x=x_i-x_j$  使用引理然后 Union Bound。

## 7 参数估计

估计量：样本的函数，用于估计未知参数。

**偏差**：Bias( $\hat{\theta}$ )= $E(\hat{\theta})-\theta$ ，Bias( $\hat{\theta}$ )=0 称为无偏估计量。若  $\lim_{n\rightarrow\infty}E(\hat{\theta})=\theta$ ，称为**渐近无偏**估计量。

**均方误差**：MSE( $\hat{\theta}$ )= $E((\hat{\theta}-\theta)^2)=\text{Var}(\hat{\theta})+(\text{Bias}(\hat{\theta}))^2$ 。若无偏则 MSE( $\hat{\theta}$ )=Var( $\hat{\theta}$ )。

**一致估计量**：若估计量  $\hat{\theta}_n\overset{P}{\rightarrow}\theta$ ，则称  $\hat{\theta}_n$  为参数  $\theta$  的一致估计量。等价于 MSE $\rightarrow 0$ 。

$k$  阶矩： $A_k=\frac{1}{n}\sum_{i=1}^nX_i^k$ ,  $A_k$  是  $\mu_k=E(X^k)$  的无偏估计量，且一致。 $k$  阶中心矩： $B_k=\frac{1}{n}\sum_{i=1}^n(X_i-\overline{X})^k$ 。  $B_2$  是  $\sigma^2$  的渐近无偏估计量，且一致，但不是无偏估计量。因为  $E(B_2)=E(X^2)-E(\overline{X}^2)$ ，而  $E(\overline{X}^2)=(E(X))^2+\text{Var}(\overline{X})$ （平方的期望减期望的平方），然后  $\text{Var}(\overline{X})=\text{Var}(X)/n$ ，所以  $E(B_2)=\frac{n-1}{n}\text{Var}(X)$ 。**样本方差**  $S^2=\frac{1}{n-1}\sum_{i=1}^n(X_i-\overline{X})^2$  是 Var( $X$ ) 的无偏估计量。

**矩法**：用样本矩替换总体矩。方法是不唯一的。对于  $\sigma^2$  可以用  $S^2$ ,  $B_2$  甚至  $A_2-\overline{X}^2$ 。

**MLE**：最大化似然函数  $L(\theta)=P(\forall i,X_i=x_i)$ 。**MLE 的不变性**：若  $\hat{\theta}$  是  $\theta$  的 MLE，则  $g(\hat{\theta})$  是  $g(\theta)$  的 MLE。

**区间估计**：设计统计量  $\hat{\theta}_L(X_1,\cdots,X_n)$  和  $\hat{\theta}_U(X_1,\cdots,X_n)$ ，使得  $P(\hat{\theta}_L\leq\theta\leq\hat{\theta}_U)\geq 1-\alpha$ 。

方法：**枢轴量法**。设计枢轴量  $G$  使得  $G$  的分布与未知参数无关，然后选择  $c,d$  使得  $P(c\leq G\leq d)=1-\alpha$ ，从而得到不等式  $c\leq G(X_1,\cdots,X_n,\theta)\leq d$ ，解出  $\theta$  的区间估计。

例子：对于  $X\sim N(\mu,\sigma^2)$ ，设计  $\sigma^2$  的  $1-\alpha$  置信区间。考虑  $\frac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1)$ ，令  $\chi^2(n-1)$  分布函数  $F$ ，取  $c=F^{-1}(\alpha/2),d=F^{-1}(1-\alpha/2)$ ，则有  $P\left(c\leq\frac{(n-1)S^2}{\sigma^2}\leq d\right)=1-\alpha$ ，解出

$\sigma^2$  的区间估计为  $\left[\frac{(n-1)S^2}{d},\frac{(n-1)S^2}{c}\right]$ 。对于  $B(1,p)$ ，可以用 Chernoff  $P(|\overline{X}-p|\geq\epsilon)\leq 2e^{-2n\epsilon^2}$ ，然后让右边等于  $\alpha$  就可以解出  $\epsilon$ 。**注意对于参数  $\theta$  的区间估计的结果应该是不等号中间是参数  $\theta$**

## 7.1 技术

说明正态总体下  $\overline{X}$  和  $S^2$  独立。核心思路：**通过线性变换将缠在一起的变量  $X_1,\cdots,X_n$ （各自包含了均值和方差信息）解耦开来**。构造正交矩阵  $U$ ，第一行全为  $1/\sqrt{n}$ ，其他随意。令随机变量  $\mathbf{X}=(X_1,\cdots,X_n)$ ，令  $\mathbf{Y}=\mathbf{U}\mathbf{X}$ ，显然  $\mathbf{Y}$  服从高斯分布。注意到  $E(\mathbf{Y})=(\sqrt{n}\mu,0,\cdots,0)$ ，且 Cov( $\mathbf{Y}$ )= $\sigma^2\mathbf{I}$ 。因此  $Y_1,\cdots,Y_n$  独立，且  $Y_1\sim N(\sqrt{n}\mu,\sigma^2)$ ,  $Y_2,\cdots,Y_n\sim N(0,\sigma^2)$ 。注意到  $\overline{X}=\frac{Y_1}{\sqrt{n}}$ ，且  $\sum(X_i-\overline{X})^2=\sum_{i=2}^nY_i^2$ ，因此  $\overline{X}$  和  $S^2$  独立。

知道  $\overline{X}\sim N(\mu,\sigma^2/n)$ ， $(n-1)S^2/\sigma^2\sim\chi^2(n-1)$ （因为是  $n-1$  个独立的  $N(0,1)$  的平方和）。

对于  $X\sim\text{Exp}(\lambda)$ ，计算  $E(1/\overline{X})$  的时候可以利用  $Y\sim\Gamma(n,\lambda)$ ，然后可以化出分子和分母的  $\Gamma$  函数，消掉。

## 8 回归分析

### 8.1 一元线性回归

回归分析： $y=\alpha+\beta x+\epsilon$ ，其中  $\epsilon$  为误差项， $E(\epsilon)=0$ , Var( $\epsilon$ )= $\sigma^2$ 。

**最小二乘**： $Q(\alpha,\beta)=\sum_{i=1}^n(y_i-\beta x_i-\alpha)^2$ ，使得  $Q$  最小的  $\hat{\alpha},\hat{\beta}$  称为最小二乘估计。求偏导然后令为 0 可得

$$\hat{\beta}=\frac{S_{xy}}{S_{xx}},\hat{\alpha}=\overline{y}-\hat{\beta}\overline{x}$$

其中  $S_{xy}=\sum_{i=1}^n(x_i-\overline{x})(y_i-\overline{y})$ ,  $S_{xx}=\sum_{i=1}^n(x_i-\overline{x})^2$ 。

**一个很关键的技巧**： $\sum(x_i-\overline{x})=0$ ，因此可以对比如  $\sum(x_i-\overline{x})(x_i)$  的式子进行处理成  $s_{xx}$  的形式。

**无偏性**： $\hat{\beta}=\beta+\sum\epsilon_i(x_i-\overline{x})/s_{xx}$ ,  $\hat{\alpha}=\alpha+\sum\epsilon_i\left(\frac{1}{n}-\frac{(x_i-\overline{x})}{s_{xx}}\cdot\overline{x}\right)$

**估计量的方差与协方差**：MSE( $\hat{\beta}$ )=Var( $\hat{\beta}$ )= $\sigma^2/s_{xx}$ ,

MSE( $\hat{\alpha}$ )=Var( $\hat{\alpha}$ )= $\sigma^2\left(\frac{1}{n}+\frac{(\overline{x})^2}{s_{xx}}\right)$ ，算协方差的时候同样考虑只有交叉项有贡献，Cov( $\hat{\alpha},\hat{\beta}$ )= $-\sigma^2\cdot\frac{\overline{x}}{s_{xx}}$ 。

**预测值的无偏性与方差**：预测值  $\hat{y}_i=\hat{\alpha}+\hat{\beta}x_i$ ,  $E(\hat{y}_i)=\alpha+\beta x_i$ ，所以无偏。Var( $\hat{y}_i$ )= $\sigma^2\left[\frac{1}{n}+\frac{(x_i-\overline{x})^2}{s_{xx}}\right]$ ，通过

Var( $\hat{y}_i$ )=Var( $\hat{\alpha}$ )+ $x_i^2$ Var( $\hat{\beta}$ )+ $2x_i$ Cov( $\hat{\alpha},\hat{\beta}$ ) 计算。

**残差的方差**：残差  $e_i=y_i-\hat{y}_i$ ,  $E(e_i)=0$ ，展开方差的公式来计算

$$\text{Var}(e_i)=\sigma^2\left[1-\frac{1}{n}-\frac{(x_i-\overline{x})^2}{s_{xx}}\right]。$$

$\sigma^2$  的**无偏估计**： $E(\sum(\hat{y}_i-y_i)^2)=\sum\text{Var}(\hat{y}_i-y_i)=(n-2)\sigma^2$ ，所以  $s^2=\frac{1}{n-2}\sum(\hat{y}_i-y_i)^2$  为无偏估计量。

**最大似然**：需要  $\epsilon_i\sim N(0,\sigma^2)$  且相互独立，对于  $\alpha,\beta$  等价于最小二乘，但是  $\sigma_{\text{MLE}}^2=\frac{1}{n}\sum(y_i-\hat{y}_i)^2$ ，是有偏的。 $\hat{\alpha}$  和  $\hat{\beta}$  服从正态分布（方差我们之前计算过）。若  $s^2=\frac{1}{n-2}\sum(\hat{y}_i-y_i)^2$ ，则  $\frac{(n-2)s^2}{\sigma^2}\sim\chi^2(n-2)$ ，且与  $\hat{\alpha},\hat{\beta}$  独立。

### 8.2 多元线性回归

$y=\beta_0+\beta_1x_1+\beta_2x_2+\cdots+\beta_px_p+\epsilon$  写成向量的形式，发现  $y_i=\mathbf{x}_i^\top\boldsymbol{\beta}+\epsilon_i$ ，其中  $\mathbf{x}=(1,x_{i,1},\cdots,x_{i,k})$ 。定义  $\mathbf{Q}(\boldsymbol{\beta})=\sum(y_i-\boldsymbol{\beta}^\top\mathbf{x}_i)^2$ ，最小化之，最小二乘估计  $\hat{\boldsymbol{\beta}}$ 。经验回归函数为  $\hat{\mathbf{y}}=\mathbf{X}^\top\hat{\boldsymbol{\beta}}$

矩阵形式即为  $\mathbf{X}\in\mathbb{R}^{n\times(k+1)}$ ，这个时候  $Q(\boldsymbol{\beta})=|\mathbf{y}-\mathbf{X}\boldsymbol{\beta}|^2$ 。正规方程为  $\nabla Q=-2\mathbf{X}^\top(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})=0$ ，若  $\mathbf{X}$  列满秩，则  $\hat{\boldsymbol{\beta}}=(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$ 。发现  $\hat{\boldsymbol{\beta}}=(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top(\mathbf{X}\boldsymbol{\beta}+\boldsymbol{\epsilon})=\boldsymbol{\beta}+(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\boldsymbol{\epsilon}$ ，所以  $E(\hat{\boldsymbol{\beta}})=\boldsymbol{\beta}$ ，无偏。Cov( $\hat{\boldsymbol{\beta}}$ )= $\sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}$ 。

这里接下来处理一元的情况，注意到  $\mathbf{X}^\top\mathbf{X}=\left(\sum x_i\quad\sum x_i^2\right)$  所以行列式为  $n\cdot s_{xx}$ ，于是 Cov( $\hat{\beta}$ )= $\frac{\sigma^2}{n\cdot s_{xx}}\begin{pmatrix}\sum x_i^2&-n\overline{x}\\-n\overline{x}&n\end{pmatrix}$ ，可以和之前的一元结果对应上。

$\hat{\mathbf{y}}=\mathbf{X}\hat{\boldsymbol{\beta}}=\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$ ，令  $\mathbf{H}=\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$ 。性质： $\text{tr}(\mathbf{H})=\text{tr}(\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top)=\text{tr}((\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X})=\text{tr}(\mathbf{I})=k+1$  (trace trick),  $\mathbf{H}^2=\mathbf{H}$ ,  $(\mathbf{I}-\mathbf{H})^2=\mathbf{I}-\mathbf{H}$ ,  $\mathbf{H}\mathbf{X}=\mathbf{X}$ ,  $\mathbf{H}$  对称且半正定。其本质是**投影矩阵**，将任意向量投影到  $\mathbf{X}$  的列空间上，所以  $\mathbf{y}-\hat{\mathbf{y}}$  垂直于该列空间。所以  $\hat{\mathbf{y}}-\mathbf{y}=(\mathbf{H}-\mathbf{I})\mathbf{y}=(\mathbf{H}-\mathbf{I})\boldsymbol{\epsilon}$ ，于是 Cov( $\hat{\mathbf{y}}-\mathbf{y}$ )= $\sigma^2(\mathbf{H}-\mathbf{I})(\mathbf{H}-\mathbf{I})^\top=\sigma^2(\mathbf{I}-\mathbf{H})$ ,  $E(|\hat{\mathbf{y}}-\mathbf{y}|^2)=\sigma^2\text{tr}(\mathbf{I}-\mathbf{H})=\sigma^2(n-k-1)$ ，所以  $\frac{1}{n-k-1}|\hat{\mathbf{y}}-\mathbf{y}|^2$  为  $\sigma^2$  的无偏估计量。对于一元的情况， $k=1$ 。

SST= $\sum(y_i-\overline{y})^2$ （总平方和），SSE= $\sum(\hat{y}_i-y_i)^2$ （残差平方和），SSR= $\sum(\hat{y}_i-\overline{y})^2$ （回归平方和）。有 SST=SSR+SSE。（证明：知道  $\mathbf{y}-\hat{\mathbf{y}}$  垂直于  $C(\mathbf{X})$ ，而显然  $\overline{\mathbf{y}}$  和  $\hat{\mathbf{y}}$  在列空间内，勾股定理）定义  $R^2=\text{SSR}/\text{SST}$ ，表示回归模型对总变异的解释比例。有  $R^2=1-\text{SSE}/\text{SST}$  且  $R^2\in[0,1]$ 。