

1 概率论基本概念

概率公理化：
S 为样本空间，*F* 为 *S* 的某些子集组成的事件域。如果定义在 *F* 上的实值函数 *P* 满足。
1. ∀*A*∈*F*,*P*(*A*)≥0；
2. *P*(*S*)=1；
3. ∀*A*₁,*A*₂,...∈*F* 且两两互斥，有 *P*(∪ ∞_{*i*=1} *A*_{*i*})=∑ ∞_{*i*=1} *P*(*A*_{*i*})，则称 *P* 为概率测度，(*S*,*F*,*P*) 为概率空间。

一般加法公式
P(∪ ⁿ_{*i*=1} *A*_{*i*})=∑ ⁿ_{*i*=1} *P*(*A*_{*i*})−∑ 1_{*i*≤*i*<*j*≤*n*} *P*(*A*_{*i*}*A*_{*j*})+⋯+(−1)^{*n*−1} *P*(*A*₁⋯*A*_{*n*})

贝叶斯公式
P(*A*|*B*)=*P*(*B*|*A*)·

P
(
A
)

P
(
B
)

{\displaystyle {\frac {P(A)}{P(B)}}}

相互独立比两两独立更强。

Union Bound
P(∪ ⁿ_{*i*=1} *A*_{*i*})≤∑ ⁿ_{*i*=1} *P*(*A*_{*i*})，对 *A*_{*i*} 无要求。

证明存在可以通过证明其概率大于 0

2 离散随机变量

P(*X*≥*E*(*X*))>0,*P*(*X*≤*E*(*X*))>0,Var(*aX*+*b*)=*a*²Var(*X*)

尾不等式/集中不等式：随机变量与期望的偏离。

Markov: 对非负 *X*, *E*(*X*)>0,*a*>0, 有

P
(
X
≥
a
)
≤
E
(
X
)

/

a

P
(
X
≥
a
E
(
X
)
)
≤
1

/

a

{\displaystyle P(X\geq a)\leq E(X)/a \ \ P(X\geq aE(X))\leq 1/a}

Chebyshev: 对 *σ*(*X*)>0,*c*>0,

P
(
|
X
−
E
(
X
)
|
≥
c
⋅
σ
(
X
)
)
≤
1

/

c

2

{\displaystyle P(|X-E(X)|\geq c\cdot \sigma (X))\leq 1/c^{2}}

P
(
|
X
−
E
(
X
)
|
≥
a
)
≤
Var
(
X
)

/

a

2

{\displaystyle P(|X-E(X)|\geq a)\leq \mathrm {Var} (X)/a^{2}}

| 分布 | 分布列 <i>P</i> (<i>X</i> = <i>k</i>)= | 期望 | 方差 |
|-----------------------------------|---|---|---|
| <i>B</i> (<i>n</i> , <i>p</i>) | (n k) p k (1 −<!-- − --> p) n −<!-- − --> k {\displaystyle {\binom {n}{k}}p^{k}(1-p)^{n-k}} | <i>np</i> | <i>np</i> (1− <i>p</i>) |
| <i>G</i> (<i>p</i>) | <i>p</i> (1− <i>p</i>) ^{<i>k</i>−1} | 1 p {\displaystyle {\frac {1}{p}}} | 1 −<!-- − --> p p 2 {\displaystyle {\frac {1-p}{p^{2}}}} |
| π(<i>λ</i>) | λ<!-- λ --> k e −<!-- − --> λ<!-- λ --> / k ! {\displaystyle {\lambda ^{k}e^{-\lambda }/k!}} | <i>λ</i> | <i>λ</i> |
| <i>NB</i> (<i>r</i> , <i>p</i>) | (r −<!-- − --> 1 k −<!-- − --> 1) p r (1 −<!-- − --> p) k −<!-- − --> r {\displaystyle {\binom {r-1}{k-1}}p^{r}(1-p)^{k-r}} | r p {\displaystyle {\frac {r}{p}}} | r (1 −<!-- − --> p) p 2 {\displaystyle {\frac {r(1-p)}{p^{2}}}} |

二项分布: *n* 次独立重复伯努利实验成功次数。**几何分布**: 第一次成功的试验次数。**负二项分布**: 第 *r* 次成功的次数。有 *G*(*p*)=*NB*(1,*p*)。
泊松分布: 单位时间内事件发生次数。几何分布具有**无记忆性**: *P*(*X*>*m*+*n*|*X*>*m*)=*P*(*X*>*n*)。
NB(*r*,*p*) 可以拆成 *r* 个独立的 *G*(*p*) 之和。

3 连续随机变量

正态分布: *X*~*N*(*μ*,*σ*²)，*f*(*x*)=

1

2
π
σ

exp
⁡
(
−

(
x
−
μ
)

2

2
σ

2

)
,

E
(
X
)
=
μ
,
Var
(
X
)
=

σ

2

.
标准正态分布 *Z*~*N*(0,1)。

指数分布: *X*~Exp(*λ*)，*f*(*x*)=*λe*^{−*λx*}, *F*(*x*)=*1*−*e*^{−*λx*}, *E*(*X*)=1/*λ*,Var(*X*)=1/*λ*²。具有无记忆性 *P*(*X*>*s*+*t*|*X*>*s*)=*P*(*X*>*t*)。理解为泊松分布假设下，第一次事件发生的时刻。

伽马分布: *X*~Γ(*α*,*λ*)，理解为泊松假设下第 *α* 次的时刻。

f
(
x
)
=

λ

α

Γ
(
α
)

x

α
−
1

e

−
λ
x

,
x
≥
0

{\displaystyle f(x)={\frac {\lambda ^{\alpha }}{\Gamma (\alpha)}}x^{\alpha -1}e^{-\lambda x},x\geq 0}

E(*X*)=*α*/*λ*, Var(*X*)=*α*/*λ*²。其中 Γ(*α*)=∫ 0[∞] *x*^{*α*−1}*e*^{−*x*}*dx*,Γ(*α*+1)=*α*·Γ(*α*),Γ(*n*+1)=*n*!,Γ(*n*+1⁄2)=

(
2
n
)
!

4

n

π

√
n

{\displaystyle (2n)!{\sqrt[{4n}]{\pi }}{\sqrt {n}}}

。具有可加性：Γ(*α*₁+*α*₂,*λ*)=Γ(*α*₁,*λ*)+Γ(*α*₂,*λ*)。α=1 时即指数分布。α=*n*/2,*λ*=1/2 时即 *χ*²(*n*) 分布。

概率密度变换: *Y*=*g*(*X*)，*g* 单调且反函数 *h*(*y*) 有连续导数，则 *f_Y*(*y*)=*f_X*(*h*(*y*))·|*h*'(*y*)|。如果没直接套这个公式的话可以从**分布函数**的定义出发进行变换。

4 多维离散随机变量

对于独立的 *X*,*Y*，有 Var(*X*±*Y*)=Var(*X*)+Var(*Y*)

协方差: Cov(*X*,*Y*)=*E*((*X*−*E*(*X*))(*Y*−*E*(*Y*)))=*E*(*XY*)−*E*(*X*)*E*(*Y*)。

Var(*X*₁+⋯+*X*_{*n*})=∑ ⁿ_{*i*=1}∑ ⁿ_{*j*=1} Cov(*X*_{*i*},*X*_{*j*})，

Var(*X*+*Y*)=Var(*X*)+Var(*Y*)+2Cov(*X*,*Y*)，

Cov(*aX*,*bY*)=*ab*·Cov(*X*,*Y*)，

Cov(*X*₁+*X*₂,*Y*)=Cov(*X*₁,*Y*)+Cov(*X*₂,*Y*)

条件期望: *E*(*X*|*Y*=*y*)=∑ ⁿ_{*i*=1} *x_i* *P*(*X*=*x_i*|*Y*=*y*)，是关于 *y* 的函数。*E*(*X*|*Y*) 是随机变量。

重期望公式: *E*(*E*(*X*|*Y*))=*E*(*X*)

5 多维连续随机变量

二维高斯: *X*,*Y*~*N*(*μ*₁,*μ*₂,*σ*₁²,*σ*₂²,*ρ*)，要求 |*ρ*|<1。

1

2
π

σ

1

σ

2

√
1
−

ρ

2

exp
⁡
[
−

1

2
(
1
−

ρ

2

)

(

(
x
−

μ

1

)

2

σ

1

2

+

(
y
−

μ

2

)

2

σ

2

2

−

2
ρ
(
x
−

μ

1

)
(
y
−

μ

2

)

σ

1

σ

2

)
]

{\displaystyle {\frac {1}{2\pi \sigma _{1}\sigma _{2}{\sqrt {1-\rho ^{2}}}}}\exp \left[-{\frac {1}{2(1-\rho ^{2})}}\left({\frac {(x-\mu _{1})^{2}}{\sigma _{1}^{2}}}+{\frac {(y-\mu _{2})^{2}}{\sigma _{2}^{2}}}-{\frac {2\rho (x-\mu _{1})(y-\mu _{2})}{\sigma _{1}\sigma _{2}}}\right)\right]}

边际密度函数与 *ρ* 无关。*ρ*=0 时独立。协方差 Cov(*X*,*Y*)=*ρσ*₁*σ*₂。

相关系数 Corr(*X*,*Y*)=Cov(*X*,*Y*)/*σ*(*X*)*σ*(*Y*)。相关系数/协方差大于 0 则正相关，小于 0 则负相关，等于 0 则不相关（但不一定独立）。相关系数等于 ±1 代表 *X*,*Y* 呈严格线性关系。证明考虑标准化 *X̂*,*Ŷ*，然后通过 Var(*X̂*−*Ŷ*)=0 推导出 *P*(*X̂*−*Ŷ*=*c*)=1。

5.1 概率密度变换

卷积公式: 若 *X*,*Y* 独立，*Z*=*X*+*Y*，则

f

Z

(
z
)
=

∫

−
∞

f

X

(
x
)

f

Y

(
z
−
x
)
d
x
=

∫

−
∞

f

X

(
z
−
y
)

f

Y

(
y
)
d
y

{\displaystyle f_{Z}(z)=\int _{-\infty }^{\infty }f_{X}(x)f_{Y}(z-x)\mathrm {d} x=\int _{-\infty }^{\infty }f_{X}(z-y)f_{Y}(y)\mathrm {d} y}

min/max: 若 *X*₁,⋯,*X_n* 独立，则 *Y*=max{*X_i*} 的分布函数为 *F_Y*(*y*)=∏ ⁿ_{*i*=1} *F_{X_i}*(*y*)，*Y*=min{*X_i*} 的分布函数为 *F_Y*(*y*)=1−∏ ⁿ_{*i*=1} (1−*F_{X_i}*(*y*))。

换元: *X*,*Y* 的概率密度为 *f*(*x*,*y*)，函数 *u*=*u*(*x*,*y*) 和 *v*=*v*(*x*,*y*) 偏导连续且 *x*=*x*(*u*,*v*),*y*=*y*(*u*,*v*) 为唯一反函数，则 *U*=*u*(*X*,*Y*),*V*=*v*(*X*,*Y*) 的联合概率密度为

g
(
u
,
v
)
=
f
(
x
(
u
,
v
)
,
y
(
u
,
v
)
)
⋅
|
J
|
,
J
=
|

∂
x

∂
(
u
,
v
)

|

=
|

∂
x

∂
u

∂
x

∂
v

|

{\displaystyle g(u,v)=f(x(u,v),y(u,v))\cdot |J|,J=\left|\left|{\frac {\partial x}{\partial (u,v)}}\right|\right|=\left|\left|{\frac {\partial x}{\partial u}}{\frac {\partial x}{\partial v}}\right|\right|}

5.2 线性代数

对角化: ***A*=*PΛP*^{−1}**。保行列式，平方的行列式和 trace 不变。实对称矩阵可对角化，不同特征值的特征向量正交。

正定: 半正定矩阵 ***A*** 存在 ***B*=*A*^{1/2}**, ***B*[⊤]*B*=*B*²=*A***，且 *B* 不唯一。对于正定矩阵，这样的 ***B*** 可逆，(***B*^{−1}**)²=***A*^{−1}**。

协方差矩阵: 对于随机变量 ***X*=(*X*₁,⋯,*X_n*)**，Cov(***X***)=*E*((***X*−*E*(***X***))(***X*−*E*(***X***))[⊤]) 为协方差矩阵，有****

Cov(***X***)=

(

Var
(

X

1

)

Cov
(

X

1

,

X

2

)

⋯

Cov
(

X

1

,

X

n

)

Cov
(

X

2

,

X

1

)

Var
(

X

2

)

⋯

Cov
(

X

2

,

X

n

)

⋮

⋮

⋮

Cov
(

X

n

,

X

1

)

Cov
(

X

n

,

X

2

)

⋯

Var
(

X

n

)

)

{\displaystyle \mathrm {Cov} (\mathbf {X})={\begin{pmatrix}\mathrm {Var} (X_{1})&\mathrm {Cov} (X_{1},X_{2})&\cdots &\mathrm {Cov} (X_{1},X_{n})\\{\mathrm {Cov} (X_{2},X_{1})}&\mathrm {Var} (X_{2})&\cdots &\mathrm {Cov} (X_{2},X_{n})\\\vdots &\vdots &\ddots &\vdots \\{\mathrm {Cov} (X_{n},X_{1})}&\mathrm {Cov} (X_{n},X_{2})&\cdots &\mathrm {Var} (X_{n})\end{pmatrix}}

其对称且半正定。

高斯: *n* 维高斯的联合密度函数，***B*** 为协方差矩阵：

f
(
x
)
=

1

(
2
π
)

n

2

(
det
⁡
B
)

n

2

exp
⁡
(
−

1

2

⋅
(
x
−
μ
)

⊤

B

−
1

(
x
−
μ
)

)

{\displaystyle f(\mathbf {x})={\frac {1}{(2\pi)^{\frac {n}{2}}(\det \mathbf {B})^{\frac {n}{2}}}}\exp \left(-{\frac {1}{2}}\cdot (\mathbf {x} -\mathbf {\mu })^{\top }\mathbf {B} ^{-1}(\mathbf {x} -\mathbf {\mu })\right)}

若 ***X*~*N*(***μ***,***B***)**，令 ***Y*=*A**X*+*b***，且 ***A*** 行满秩，则 *Y*~*N*(***Aμ*+*b***,***ABA*[⊤]**)

6 尾不等式、大数定律与中心极限定理

尾不等式: *P*(*X*≥*k*) 的上界。集中不等式：

P(|*X*−*E*(*X*)|≥*k*) 的上界。

矩: *E*(*X*^{*n*}) 称为 *X* 的 *n* 阶矩，*E*((*X*−*E*(*X*))^{*n*}) 称为 *X* 的 *n* 阶中心矩。切比雪夫不等式的本质是对二阶中心矩使用 Markov。

矩生成函数: *M_X*(*t*)=*E*(*e*^{*tX*})=∑ ⁿ_{*i*≥0}

t

i

i
!

E
(

X

i

)

{\displaystyle M_{X}(t)=E(e^{tX})=\sum _{i\geq 0}{\frac {t^{i}}{i!}}E(X^{i})}

。所以求 *k* 阶矩可以求其封闭形式的 *k* 阶导数后令 *t*=0。

Chernoff Bound: 求 *k* 阶中心矩然后用 Markov 得到的尾不等式通常较弱（没有真正用到 *n* 重伯努利实验的独立性）。对于任意 *t*>0, 有

P
(
X
≥
a
)
=
P

(

e

t
X

≥

e

t
a

)
≤

E
(

e

t
X

)

e

t
a

=

e

−
t
a

M

X

(
t
)

{\displaystyle P(X\geq a)=P(e^{tX}\geq e^{ta})\leq {\frac {E(e^{tX})}{e^{ta}}}={e^{-ta}}M_{X}(t)}

对于任意 *t*<0 有 *P*(*X*≤*a*)≤*M_X*(*t*)·*e*^{−*t**a*} 通过调节 *t* 可得到更紧的上界。一般而言是**求导**找最小值。

Hoeffding 引理: 若实数随机变量 *a*≤*X*≤*b*，则对任意实数 *t* 有

E
(

e

t
(
X
−
E
(
X
)
)

)
≤
exp
⁡
(

t

2

(
b
−
a

)

2

8

)

{\displaystyle E(e^{t(X-E(X))})\leq \exp \left({\frac {t^{2}(b-a)^{2}}{8}}\right)}

Chernoff-Hoeffding 不等式: *X*₁,⋯,*X_n* 独立，且 *a_i*≤*X_i*≤*b_i*，令 *X*=∑ ⁿ_{*i*=1} *X_i*，则对任意 *t*>0 有

P
(
X
≥
E
(
X
)
+
t
)
≤
exp
⁡
(

−
2

t

2

∑

n

i
=
1

(

b

i

−

a

i

)

2

)

{\displaystyle P(X\geq E(X)+t)\leq \exp \left({\frac {-2t^{2}}{\sum _{i=1}^{n}(b_{i}-a_{i})^{2}}}\right)}

P
(
X
≤
E
(
X
)
−
t
)
≤
exp
⁡
(

−
2

t

2

∑

n

i
=
1

(

b

i

−

a

i

)

2

)

{\displaystyle P(X\leq E(X)-t)\leq \exp \left({\frac {-2t^{2}}{\sum _{i=1}^{n}(b_{i}-a_{i})^{2}}}\right)}

对于 *a*≤*X_i*≤*b* 的情况，分母就是 *n*(*b*−*a*)²。

大数定律的一般形式：对于随机变量 {*X_n*}，对于任意 *ε*>0, 若

lim

n
→
∞

P
(
|

(

1
n

∑

n

i
=
1

X

i

−

1
n

∑

n

i
=
1

E
(

X

i

)

|

<
ϵ
)
=
1

{\displaystyle \lim _{n\rightarrow \infty }P\left(\left|{\frac {1}{n}}\sum _{i=1}^{n}X_{i}-{\frac {1}{n}}\sum _{i=1}^{n}E(X_{i})\right|<\epsilon \right)=1}

Markov 大数定律:

1

n

2

Var
(

∑

n

i
=
1

X

i

)
→
0
，则 {*X_n*} 满足大数定律的一般形式。

辛钦大数定律: {*X_n*} 独立同分布，且 *E*(*X_i*)=*μ*，则 {*X_n*} 满足大数定律的一般形式。对比 Markov，需要 iid，但不需要方差。

依概率收敛：随机变量序列 {*X_n*} 依概率收敛于 *X*，记作

X_n

→

P

X
,

{\displaystyle X_{n}\rightarrow ^{P}X,}

 如果对任意 *ε*>0, 有

lim

n
→
∞

P
(
|

X

n

−
X
|
≥
ϵ
)
=
0

{\displaystyle \lim _{n\rightarrow \infty }P(|X_{n}-X|\geq \epsilon)=0}

依分布收敛：随机变量序列 {*X_n*} 依分布收敛于 *X*，记作

X_n

→

d

X
,

{\displaystyle X_{n}\rightarrow ^{d}X,}

 如果对任意 *x*, *F_{X_n}*(*x*)→*F_X*(*x*)。
依概率收敛可以推出依分布收敛，反之不亦然

几乎必然收敛：随机变量序列 {*X_n*} 几乎必然收敛于 *X*，记作 *X_n*

→

a.s.

X
,

{\displaystyle X_{n}\rightarrow ^{a.s.}X,}

 如果 ∀*ε*>0

lim

n
→
∞

P
(

⋃

m
=
n

∞

|

X

m

−
X
|
≥
ϵ
)
=
1

{\displaystyle \lim _{n\rightarrow \infty }P\left(\bigcup _{m=n}^{\infty }|X_{m}-X|\geq \epsilon \right)=1}

7 参数估计

估计量：样本的函数，用于估计未知参数。

偏差: Bias(*θ̂*)=*E*(*θ̂*)−*θ*，Bias(*θ̂*)=0 称为无偏估计量。若 lim_{*n*→∞} *E*(*θ̂*)=*θ*，称为**渐近无偏**估计量。

均方误差: MSE(*θ̂*)=*E*((*θ̂*−*θ*)²)=Var(*θ̂*)+(Bias(*θ̂*))²。若 无偏则 MSE(*θ̂*)=Var(*θ̂*)。

一致估计量: 若估计量 *θ̂_n*

→

P

θ