

Misc

- $n \in \mathbb{N}^*$, $\forall k \in \mathbb{Z}, k \geq 4\log_2 n$, 有 $k! \geq n^3$
- $\forall x \geq -1$, $\ln(1+x) \leq x$; $\forall x \leq 1/2$, $\ln(1-x) \geq -x - x^2$
- $\exp(x) \geq x+1$
- $\frac{d}{dt} \int_{a(t)}^{b(t)} f(x) dx = f(b(t))b'(t) - f(a(t))a'(t)$
- Gram-Schmidt 正交化!
- 非负离散: $E(X) = \sum_{x=0}^{+\infty} P(X > x)$, 连续 $E(X) = \int_0^{+\infty} P(X > x) dx$
- $\int_{-\infty}^{+\infty} e^{-t^2} dt = \sqrt{\pi}$ (高斯积分)
- 分部积分: $\int u dv = uv - \int v du$
- 凑微分: $\int df(u) = \int f'(u) du$
- $\ln(1-x) = -\sum_{k \geq 1} \frac{x^k}{k}$, $(1+x)^\alpha = \sum_{k \geq 0} \binom{\alpha}{k} x^k$
- $\int (ax+b)^n dx = \frac{(ax+b)^{n+1}}{a(n+1)} + C$, 也即 $\int x^n dx = \frac{x^{n+1}}{n+1} + C$

1 概率论基本概念

概率公理化: S 为样本空间, F 为 S 的某些子集组成事件域。如果定义在 F 上的实值函数 P 满足。1. $\forall A \in F, P(A) \geq 0$; 2. $P(S) = 1$; 3. $\forall A_1, A_2, \dots \in F$ 且两两互斥, 有 $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$, 则称 P 为概率测度, (S, F, P) 为概率空间。

一般加法公式: $P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i A_j) + \dots + (-1)^{n-1} P(A_1 \dots A_n)$

贝叶斯公式: $P(A|B) = P(B|A) \cdot \frac{P(A)}{P(B)}$

相互独立比两两独立更强。

Union Bound: $P(\bigcup A_i) \leq \sum P(A_i)$, 对 A_i 无要求。

证明存在可以通过证明其概率大于 0

2 离散随机变量

$P(X \geq E(X)) > 0, P(X \leq E(X)) > 0, \text{Var}(aX+b) = a^2 \text{Var}(X)$

尾不等式/集中不等式: 随机变量与期望的偏离。

Markov: 对非负 X , $E(X) > 0, a > 0$, 有

$$P(X \geq a) \leq \frac{E(X)}{a} \quad P(X \geq aE(X)) \leq \frac{1}{a}$$

Chebyshev: 对 $\sigma(X) > 0, c > 0$,

$$\begin{aligned} P(|X - E(X)| \geq c \cdot \sigma(X)) &\leq 1/c^2 \\ P(|X - E(X)| \geq a) &\leq \text{Var}(X)/a^2 \end{aligned}$$

分布	分布列 $P(X=k) =$	期望	方差
$B(n,p)$	$\binom{n}{k} p^k (1-p)^{n-k}$	np	$np(1-p)$
$G(p)$	$p(1-p)^{k-1}$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
$\pi(\lambda)$	$\lambda^k e^{-\lambda} / k!$	λ	λ
$NB(r,p)$	$\binom{k-1}{r-1} p^r (1-p)^{k-r}$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$

二项分布: n 次独立重复伯努利实验成功次数。**几何分布:** 第一次成功的试验次数。**负二项分布:** 第 r 次成功的次数。有 $G(p) = NB(1,p)$ 。**泊松分布:** 单位时间内事件发生次数。几何分布具有无记忆性:

$P(X > m+n | X > m) = P(X > n)$ 。 $NB(r,p)$ 可以拆成 r 个独立的 $G(p)$ 之和。

3 连续随机变量

正态分布: $X \sim N(\mu, \sigma^2)$, $f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp(-\frac{(x-\mu)^2}{2\sigma^2})$, $E(X) = \mu, \text{Var}(X) = \sigma^2$ 。标准正态分布 $Z \sim N(0,1)$.

指数分布: $X \sim \text{Exp}(\lambda)$, $f(x) = \lambda e^{-\lambda x}$, $F(x) = 1 - e^{-\lambda x}$, $E(X) = 1/\lambda, \text{Var}(X) = 1/\lambda^2$ 。具有无记忆性 $P(X > s+t | X > s) = P(X > t)$ 。理解为泊松分布假设下, 第一次事件发生的时刻。

伽马分布: $X \sim \Gamma(\alpha, \lambda)$, 理解为泊松假设下第 α 次的时刻。

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, x \geq 0$$

$E(X) = \alpha/\lambda$, $\text{Var}(X) = \alpha/\lambda^2$ 。其中 $\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx$, $\Gamma(\alpha+1) = \alpha \cdot \Gamma(\alpha), \Gamma(n+1) = n!, \Gamma(n+\frac{1}{2}) = \frac{(2n)!}{4^n n!} \sqrt{\pi}$ 。具有可加性:

$\Gamma(\alpha_1 + \alpha_2, \lambda) = \Gamma(\alpha_1, \lambda) + \Gamma(\alpha_2, \lambda)$ 。 $\alpha = 1$ 时即指数分布。 $\alpha = n/2, \lambda = 1/2$ 时即 $\chi^2(n)$ 分布。

概率密度变换: $Y = g(X)$, g 单调且反函数 $h(y)$ 有连续导数, 则 $f_Y(y) = f_X(h(y)) \cdot |h'(y)|$ 。如果没法直接套这个公式的话可以从分布函数的定义出发进行变换。即先算 $P(Y \leq y)$ 再求导。

4 多维离散随机变量

对于独立的 X, Y , 有 $\text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y)$

协方差: $\text{Cov}(X, Y) = E((X - E(X))(Y - E(Y))) = E(XY) - E(X)E(Y)$.

$\text{Var}(X_1 + \dots + X_n) = \sum_i \sum_j \text{Cov}(X_i, X_j)$,

$\text{Var}(X+Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$,

$\text{Cov}(aX, bY) = ab \cdot \text{Cov}(X, Y)$,

$\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$,

$\text{Cov}(X, Y) \leq \sqrt{\text{Var}(X)\text{Var}(Y)}$

条件期望: $E(X|Y=y) = \sum_i x_i P(X=x_i | Y=y)$, 是关于 y 的函数。

$E(X|Y)$ 是随机变量。

重期望公式: $E(E(X|Y)) = E(X)$

5 多维连续随机变量

条件分布函数: $F(x|y) = P(X \leq x | Y=y) = \int_{-\infty}^x \frac{f(u,y)}{f_Y(y)} du$

条件密度函数: $f(x|y) = \frac{\partial}{\partial x} F(x|y) = \frac{f(x,y)}{f_Y(y)}$.

二维高斯: $X, Y \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 要求 $|\rho| < 1$.

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left[-\frac{1}{2(1-\rho^2)} \left(\frac{(x-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} \right)\right]$$

边际密度函数与 ρ 无关, 即 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$ 。 $\rho = 0$ 时独立。

协方差: $\text{Cov}(X, Y) = \rho\sigma_1\sigma_2$ 。

相关系数: $\text{Corr}(X, Y) = \text{Cov}(X, Y) / \sigma(X)\sigma(Y)$ 。相关系数/协方差大于 0 则正相关, 小于 0 则负相关, 等于 0 则不相关 (但不一定独立)。相关系数等于 ± 1 代表 X, Y 呈严格线性关系。证明考虑标准化 \tilde{X}, \tilde{Y} , 然后通过 $\text{Var}(\tilde{X} - \tilde{Y}) = 0$ 推导出 $P(\tilde{X} - \tilde{Y} = c) = 1$ 。

5.1 概率密度变换

卷积公式: 若 X, Y 独立, $Z = X + Y$, 则

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx = \int_{-\infty}^{\infty} f_X(z-y) f_Y(y) dy$$

min/max: 若 X_1, \dots, X_n 独立, 则 $Y = \max\{X_i\}$ 的分布函数为

$F_Y(y) = \prod_{i=1}^n F_{X_i}(y)$, $Y = \min\{X_i\}$ 的分布函数为

$F_Y(y) = 1 - \prod_{i=1}^n (1 - F_{X_i}(y))$.

换元: X, Y 的概率密度为 $f(x, y)$, 函数 $u = u(x, y)$ 和 $v = v(x, y)$ 偏导连续且 $x = x(u, v), y = y(u, v)$ 为唯一反函数, 则 $U = u(X, Y), V = v(X, Y)$ 的联合概率密度为

$$g(u, v) = f(x(u, v), y(u, v)) \cdot |J|, J = \begin{vmatrix} \frac{\partial(x, y)}{\partial(u, v)} & \frac{\partial(x, y)}{\partial(v)} \\ \frac{\partial(u, v)}{\partial(u, v)} & \frac{\partial(u, v)}{\partial(v)} \end{vmatrix}$$

5.2 线性代数

对角化: $A = P \Lambda P^{-1}$ 。保行列式, 平方的行列式和 trace 不变。实对称矩阵可对角化, 不同特征值的特征向量正交。

正定: 半正定矩阵 A 存在 $B = A^{1/2}$, $B^T B = B^2 = A$, 且 B 不唯一。对于正定矩阵, 这样的 B 可逆, $(B^{-1})^2 = A^{-1}$ 。

协方差矩阵: 对于随机变量 $\mathbf{X} = (X_1, \dots, X_n)$,

$\text{Cov}(\mathbf{X}) = E((\mathbf{X} - E(\mathbf{X}))(\mathbf{X} - E(\mathbf{X}))^\top)$ 为协方差矩阵, 有

$$\text{Cov}(\mathbf{X}) = \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \dots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \dots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \dots & \text{Var}(X_n) \end{pmatrix}$$

其对称且半正定。

高斯: n 维高斯的联合密度函数, \mathbf{B} 为协方差矩阵:

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{n}{2}} (\det \mathbf{B})^{\frac{1}{2}}} \exp\left(-\frac{1}{2} \cdot (\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{B}^{-1} (\mathbf{x} - \boldsymbol{\mu})\right)$$

若 $\mathbf{X} \sim N(\boldsymbol{\mu}, \mathbf{B})$, 令 $\mathbf{Y} = \mathbf{AX} + \mathbf{b}$, 且 \mathbf{A} 行满秩, 则 $\mathbf{Y} \sim N(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{ABA}^\top)$

5.3 结论

- 对于独立的 $X_i \sim N(\mu_i, \sigma_i^2)$, 有

$$\sum a_i X_i \sim N\left(\sum a_i \mu_i, \sum a_i^2 \sigma_i^2\right)$$

- 对于单个 $X_i \sim N(0, 1)$, 有 $X_i^2 \sim \chi^2(1) = \Gamma(1/2, 1/2)$, 且 $\sum_{i=1}^n X_i^2 \sim \chi^2(n) = \Gamma(\frac{n}{2}, \frac{1}{2})$

6 尾不等式、大数定律与中心极限定理

6.1 尾不等式

尾不等式: $P(X \geq k)$ 的上界。集中不等式: $P(|X - E(X)| \geq k)$ 的上界。

矩: $E(X^n)$ 称为 X 的 n 阶矩, $E((X - E(X))^n)$ 称为 X 的 n 阶中心矩。

切比雪夫不等式的本质是对二阶中心矩使用 Markov。

矩生成函数: $M_X(t) = E(e^{tX}) = \sum_{i \geq 0} \frac{t^i}{i!} E(X^i)$ 。所以求 k 阶矩可以求其封闭形式的 k 阶导然后令 $t=0$ 。

Chernoff Bound: 求 k 阶中心矩然后用 Markov 得到的尾不等式通常较弱 (没有真正用到 n 重伯努利实验的独立性)。对于任意 $t > 0$, 有

$$P(X \geq a) = P(e^{tX} \geq e^{ta}) \leq \frac{E(e^{tX})}{e^{ta}} = e^{-ta} M_X(t)$$

对于任意 $t < 0$ 有 $P(X \leq a) \leq M_X(t) \cdot e^{-ta}$ 通过调节 t 可得到更紧的上界。一般而言是求寻找最小值。但是 Chernoff Bound 不一定是最紧的。

Hoeffding 引理: 若实数随机变量 $a \leq X \leq b$, 则对任意实数 t 有

$$E(e^{t(X-E(X))}) \leq \exp\left(\frac{t^2(b-a)^2}{8}\right)$$

Chernoff-Hoeffding 不等式: X_1, \dots, X_n 独立, 且 $a_i \leq X_i \leq b_i$, 令 $X = \sum_{i=1}^n X_i$, 则对任意 $t > 0$ 有

$$P(X \geq E(X) + t) \leq \exp\left(-\frac{-2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right)$$

$$P(X \leq E(X) - t) \leq \exp\left(-\frac{-2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right)$$

对于 $a \leq X_i \leq b$ 的情况, 分母就是 $n(b-a)^2$ 。

6.2 尾不等式结论

矩生成函数的应用：对于要算 e^X 的期望，可以先算矩生成函数然后令 $t=1$ 。

矩生成函数：

- $X \sim B(n, p)$, $M_X(t) = (1-p+e^t p)^n$
- $X \sim \pi(\lambda)$, $M_X(t) = \exp(\lambda(e^t - 1))$
- $X \sim N(\mu, \sigma^2)$, $M_X(t) = \exp(\mu t + \frac{\sigma^2 t^2}{2})$

常见 Chernoff-Hoeffding 界：

- $X \sim \pi(\lambda)$, $P(X \geq x) \leq \frac{e^{-\lambda(e\lambda)^x}}{x^x}$
- $X \sim N(\mu, \sigma^2)$, $P(X \geq E(X) + k\sigma) \leq \exp(-k^2/2)$
- $X \sim B(n, p)$, $P(|X - E(X)| \geq n\epsilon) \leq 2 \cdot \exp(-2n\epsilon^2)$

对期望分段放缩：对于 $E(Y) = \sum_{k=1}^n P(Y=k) \cdot k$, 若我们知道对于 $k > k'$ 有 $P(Y=k) \leq c$, 那么就可以分段放缩：

$$E(Y) = \sum_{k=1}^{k'} P(Y=k) \cdot k + \sum_{k=k'+1}^n P(Y=k) \cdot k$$

左边的 k 放成 k' , 右边的放成 n , 然后和 c 消掉。

6.3 大数定律

大数定律的一般形式：对于随机变量 $\{X_n\}$, 对于任意 $\epsilon > 0$, 若

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \epsilon\right) = 1$$

Markov 大数定律： $\frac{1}{n^2} \text{Var}(\sum_{i=1}^n X_i) \rightarrow 0$, 则 $\{X_n\}$ 满足大数定律的一般形式。

辛钦大数定律： $\{X_n\}$ 独立同分布, 且 $E(X_i) = \mu$, 则 $\{X_n\}$ 满足大数定律的一般形式。对比 Markov, 需要 iid, 但不需要方差。

依概率收敛：随机变量序列 $\{X_n\}$ 依概率收敛于 X , 记作 $X_n \xrightarrow{P} X$, 如果对任意 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|X_n - X| \geq \epsilon) = 0$$

依分布收敛：随机变量序列 $\{X_n\}$ 依分布收敛于 X , 记作 $X_n \xrightarrow{d} X$, 如果对任意 x , $F_{X_n}(x) \rightarrow F_X(x)$ 。依概率收敛可以推出依分布收敛, 反之不然

几乎必然收敛：随机变量序列 $\{X_n\}$ 几乎必然收敛于 X , 记作 $X_n \xrightarrow{a.s.} X$, 如果 $\forall \epsilon > 0$

$$\lim_{n \rightarrow \infty} P\left(\bigcup_{m=n}^{\infty} |X_m - X| \geq \epsilon\right) = 1$$

6.4 应用

6.4.1 随机快排

算法：随机一个 pivot x , 将其余元素排在两侧 L, R , 然后递归 L, R 。如何计算 $E(T)$? $T = O(\sum_{i < j} 1_{C_{i,j}})$, $C_{i,j}$ 表示 i, j 是否比较过。

发现算法比较过 i, j iff i 或 j 是 $[i, j]$ 中第一个被选为 pivot 的元素。因为每个元素被选为 pivot 的概率相等, $P(C_{i,j}) = \frac{2}{j-i+1}$ 。所以

$$E(T) = \sum_{i < j} \frac{2}{j-i+1} = O(n \log n)$$

令 D_i 表示 i 被比较的次数, 给出尾不等式。发现若 pivot 落在 $[n/4, 3n/4]$ 则 i 所在数组大小至少减小 $1/4$, 前者概率为 $1/2$ 。若至少有 $3 \log n$ 次, 则完成排序。即 $(3/4)^{3 \log n} \leq 1/n$ 。所以 $P(D_i > 20 \log n) \leq P(X_i < 3 \log n)$, $X_i \sim B(20 \log n, 1/2)$ 。 $P(X_i < 3 \log n) \leq \exp(-4 \log n) \leq 1/n^4$ 。Union Bound 一下 $P(T > 20 \log n) \leq 1/n^3$ 。

6.4.2 JL 降维

结论：给定 $x_i \in \mathbb{R}^n$, 存在线性映射 $F: \mathbb{R}^n \rightarrow \mathbb{R}^k$, 其中 $m = O(\epsilon^{-2} \log N)$, $\geq 1/2$ 概率 $\forall i, j$, $(1-\epsilon) \|x_i - x_j\|_2^2 \leq \|F(x_i) - F(x_j)\|_2^2 \leq (1+\epsilon) \|x_i - x_j\|_2^2$ 。
 $F = \frac{1}{\sqrt{k}} \cdot Ax$, 其中 A 的每个元素独立服从 $N(0, 1)$ 。

思路：对所有可能的 $x = x_i - x_j$ 使用引理然后 Union Bound。

7 参数估计

估计量：样本的函数，用于估计未知参数。

偏差： $\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta$, $\text{Bias}(\hat{\theta}) = 0$ 称为无偏估计量。若

$\lim_{n \rightarrow \infty} E(\hat{\theta}) = \theta$, 称为渐近无偏估计量。

均方误差： $\text{MSE}(\hat{\theta}) = E((\hat{\theta} - \theta)^2) = \text{Var}(\hat{\theta}) + (\text{Bias}(\hat{\theta}))^2$ 。若无偏则 $\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta})$ 。

一致估计量：若估计量 $\hat{\theta}_n \xrightarrow{P} \theta$, 则称 $\hat{\theta}_n$ 为参数 θ 的一致估计量。等价于 $\text{MSE} \rightarrow 0$ 。

k 阶矩： $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$, A_k 是 $\mu_k = E(X^k)$ 的无偏估计量, 且一致。 k 阶中心矩： $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ 。 B_2 是 σ^2 的渐近无偏估计量, 且一致, 但不是无偏估计量。因为 $E(B_2) = E(X^2) - E(\bar{X}^2)$, 而

$E(\bar{X}^2) = (E(X))^2 + \text{Var}(\bar{X})$ (平方的期望减期望的平方), 然后

$\text{Var}(\bar{X}) = \text{Var}(X)/n$, 所以 $E(B_2) = \frac{n-1}{n} \text{Var}(X)$ 。样本方差

$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是 $\text{Var}(X)$ 的无偏估计量。

矩法：用样本矩替换总体矩。**MLE**：最大化似然函数

$$L(\theta) = P(X_1 = x_1, \dots, X_n = x_n)$$

区间估计：设计统计量 $\hat{\theta}_L(X_1, \dots, X_n)$ 和 $\hat{\theta}_U(X_1, \dots, X_n)$, 使得 $P(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) \geq 1 - \alpha$ 。

方法：**枢轴量法**。设计枢轴量 G 使得 G 的分布与未知参数无关, 然后选择 c, d 使得 $P(c \leq G \leq d) = 1 - \alpha$, 从而得到不等式 $c \leq G(X_1, \dots, X_n, \theta) \leq d$, 解出 θ 的区间估计。

7.1 技术

说明正态总体下 \bar{X} 和 S^2 独立。核心思路：通过线性变换将缠在一起的变量 X_1, \dots, X_n (各自包含了均值和方差信息) 解耦开来。构造正交矩阵 U , 第一行全为 $1/\sqrt{n}$, 其他随意。令随机变量 $\mathbf{X} = (X_1, \dots, X_n)$, 令 $\mathbf{Y} = U\mathbf{X}$, 显然 \mathbf{Y} 服从高斯分布。注意到 $E(\mathbf{Y}) = (\sqrt{n}\mu, 0, \dots, 0)$, 且 $\text{Cov}(\mathbf{Y}) = \sigma^2 I$ 。因此 Y_1, \dots, Y_n 独立, 且 $Y_1 \sim N(\sqrt{n}\mu, \sigma^2)$, $Y_2, \dots, Y_n \sim N(0, \sigma^2)$ 。注意到 $\bar{X} = \frac{Y_1}{\sqrt{n}}$, 且 $\sum (X_i - \bar{X})^2 = \sum_{i=2}^n Y_i^2$, 因此 \bar{X} 和 S^2 独立。

知道 $\bar{X} \sim N(\mu, \sigma^2/n)$, $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ (因为是 $n-1$ 个独立的 $N(0, 1)$ 的平方和)。

8 回归分析

8.1 一元线性回归

回归分析： $y = \alpha + \beta x + \epsilon$, 其中 ϵ 为误差项, $E(\epsilon) = 0$, $\text{Var}(\epsilon) = \sigma^2$ 。

最小二乘： $Q(\alpha, \beta) = \sum_{i=1}^n (y_i - \beta x_i - \alpha)^2$, 使得 Q 最小的 $\hat{\alpha}, \hat{\beta}$ 称为最小二乘估计。求偏导然后令为 0 可得

$$\hat{\beta} = \frac{S_{xy}}{S_{xx}}, \hat{\alpha} = \bar{y} - \hat{\beta} \bar{x}$$

其中 $S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$, $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ 。

一个很关键的技巧： $\sum (x_i - \bar{x}) = 0$, 因此可以对比如 $\sum (x_i - \bar{x})(x_i)$ 的式子进行处理成 s_{xx} 的形式。

无偏性： $\hat{\beta} = \beta + \sum \epsilon_i (x_i - \bar{x})/s_{xx}$, $\hat{\alpha} = \alpha + \sum \epsilon_i \left(\frac{1}{n} - \frac{(x_i - \bar{x})}{s_{xx}} \right) \cdot \bar{x}$

估计量的方差与协方差： $\text{MSE}(\hat{\beta}) = \text{Var}(\hat{\beta}) = \sigma^2 / s_{xx}$,

$\text{MSE}(\hat{\alpha}) = \text{Var}(\hat{\alpha}) = \sigma^2 \left(\frac{1}{n} + \frac{(\bar{x})^2}{s_{xx}} \right)$, 算协方差的时候同样考虑只有交叉项

有贡献, $\text{Cov}(\hat{\alpha}, \hat{\beta}) = -\sigma^2 \cdot \frac{\bar{x}}{s_{xx}}$ 。

预测值的无偏性与方差：预测值 $\hat{y}_i = \hat{\alpha} + \hat{\beta} x_i$, $E(\hat{y}_i) = \alpha + \beta x_i$, 所以无偏。

$$\text{Var}(\hat{y}_i) = \sigma^2 \left[\frac{1}{n} + \frac{(x_i - \bar{x})^2}{s_{xx}} \right], \text{ 通过}$$

$\text{Var}(\hat{y}) = \text{Var}(\hat{\alpha}) + \hat{x}_i^2 \text{Var}(\hat{\beta}) + 2x_i \text{Cov}(\hat{\alpha}, \hat{\beta})$ 计算。

残差的方差：残差 $e_i = y_i - \hat{y}_i$, $E(e_i) = 0$, 展开方差的公式来计算

$$\text{Var}(e_i) = \sigma^2 \left[1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{s_{xx}} \right]。$$

σ^2 的无偏估计： $E(\sum (y_i - \bar{y})^2) = \sum \text{Var}(\hat{y}_i - \bar{y}) = (n-2)\sigma^2$, 所以 $s^2 = \frac{1}{n-2} \sum (y_i - \bar{y})^2$ 为无偏估计量。

最大似然：需要 $\epsilon_i \sim N(0, \sigma^2)$ 且相互独立, 对于 α, β 等价于最小二乘, 但是 $\hat{\sigma}^2_{\text{MLE}} = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$, 是有偏的。 $\hat{\alpha}$ 和 $\hat{\beta}$ 服从正态分布 (方差我们之前计算过)。若 $s^2 = \frac{1}{n-2} \sum (\hat{y}_i - \bar{y})^2$, 则 $\frac{(n-2)s^2}{\sigma^2} \sim \chi^2(n-2)$, 且与 $\hat{\alpha}, \hat{\beta}$ 独立。

8.2 多元线性回归

$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \epsilon$ 写成向量的形式, 发现 $y_i = \mathbf{x}_i^\top \beta + \epsilon_i$, 其中 $\mathbf{x} = (1, x_{i,1}, \dots, x_{i,k})$ 。定义 $Q(\beta) = \sum (y_i - \beta^\top \mathbf{x}_i)^2$, 最小化之, 最小二乘估计 $\hat{\beta}$ 。经验回归函数为 $\hat{y} = \mathbf{x}^\top \hat{\beta}$

矩阵形式即为 $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$, 这个时候 $Q(\beta) = |\mathbf{y} - \mathbf{X}\beta|^2$ 。正规方程为 $\nabla Q = -2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\beta) = 0$, 若 \mathbf{X} 列满秩, 则 $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 。

发现 $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\beta + \epsilon) = \beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \epsilon$, 所以 $E(\hat{\beta}) = \beta$, 无偏。 $\text{Cov}(\hat{\beta}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$ 。

这里接下来处理一元的情况, 注意到 $\mathbf{X}^\top \mathbf{X} = \left(\sum_{i=1}^n x_i \quad \sum_{i=1}^n x_i^2 \right)$ 所以行列式为 $n \cdot s_{xx}$, 于是 $\text{Cov}(\hat{\beta}) = \frac{\sigma^2}{n \cdot s_{xx}} \begin{pmatrix} \sum x_i^2 & -n\bar{x} \\ -n\bar{x} & n \end{pmatrix}$, 可以和之前的一元结果对应上。

$\hat{y} = \mathbf{X}\hat{\beta} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$, 令 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ 。性质：

$\text{tr}(\mathbf{H}) = \text{tr}(\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top) = \text{tr}((\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}) = \text{tr}(\mathbf{I}) = k+1$ (trace trick), $\mathbf{H}^2 = \mathbf{H}$, $(\mathbf{I} - \mathbf{H})^2 = \mathbf{I} - \mathbf{H}$, $\mathbf{H}\mathbf{X} = \mathbf{X}$, \mathbf{H} 对称且半正定。其本质是投影矩阵, 将任意向量投影到 \mathbf{X} 的列空间上, 所以 $\mathbf{y} - \hat{\mathbf{y}}$ 垂直于该列空间。

所以 $\hat{\mathbf{y}} - \mathbf{y} = (\mathbf{H} - \mathbf{I})\mathbf{y} = (\mathbf{H} - \mathbf{I})\epsilon$, 于是

$$\text{Cov}(\hat{\mathbf{y}} - \mathbf{y}) = \sigma^2 (\mathbf{H} - \mathbf{I})(\mathbf{H} - \mathbf{I})^\top = \sigma^2 (\mathbf{I} - \mathbf{H}),$$

$E(|\hat{\mathbf{y}} - \mathbf{y}|^2) = \sigma^2 \text{tr}(\mathbf{I} - \mathbf{H}) = \sigma^2 (n-k-1)$, 所以 $\frac{1}{n-k-1} |\hat{\mathbf{y}} - \mathbf{y}|^2$ 为 σ^2 的无偏估计量。对于一元的情况, $k=1$ 。

$\text{SST} = \sum (y_i - \bar{y})^2$ (总平方和), $\text{SSE} = \sum (\hat{y}_i - y_i)^2$ (残差平方和),

$\text{SSR} = \sum (\hat{y}_i - \bar{y})^2$ (回归平方和)。有 $\text{SST} = \text{SSR} + \text{SSE}$ 。(证明：知道 $\mathbf{y} - \hat{\mathbf{y}}$ 垂直于 $C(\mathbf{X})$, 而显然 \bar{y} 和 $\hat{\mathbf{y}}$ 在列空间内, 勾股定理) 定义

$R^2 = \text{SSR}/\text{SST}$, 表示回归模型对总变异的解释比例。有 $R^2 = 1 - \text{SSE}/\text{SST}$ 且 $R^2 \in [0, 1]$ 。